

## LUCAS TRINDADE DE SOUZA

### 1. Questão 1:

#### 1.1 (i) Aumento da base de dados

Para resolver o item (i) da primeira questão, foi necessário expandir a base de dados original que continha 4 atributos preditivos e 14 exemplos. A ampliação consistiu na adição de 2 novos atributos ("Emprego" e "Idade") para totalizar 6 atributos preditivos, e na criação de 16 novos exemplos (E15 a E30) distribuídos entre as classes de Risco (Baixo, Alto e Moderado).

Dos novos atributos, idade é classificada como “Jovem e Adulto” e emprego é dividido em “Fixo, Autônomo, Desempregado”

| A         | B                   | C      | D        | E              | F            | G      | H        |
|-----------|---------------------|--------|----------|----------------|--------------|--------|----------|
| 1 Exemplo | História de Crédito | Dívida | Garantia | Renda          | Emprego      | Idade  | Risco    |
| 2 E1      | Ruim                | Alta   | Nenhuma  | \$0 a \$15k    | Fixo         | Adulto | Alto     |
| 3 E2      | Desconhecida        | Alta   | Nenhuma  | \$15 a \$35k   | Autônomo     | Jovem  | Alto     |
| 4 E3      | Desconhecida        | Baixa  | Nenhuma  | \$15 a \$35k   | Fixo         | Jovem  | Moderado |
| 5 E4      | Desconhecida        | Baixa  | Nenhuma  | \$0 a \$15k    | Desempregado | Adulto | Alto     |
| 6 E5      | Desconhecida        | Baixa  | Nenhuma  | Acima de \$35k | Fixo         | Adulto | Baixo    |
| 7 E6      | Desconhecida        | Baixa  | Adequada | Acima de \$35k | Fixo         | Adulto | Baixo    |
| 8 E7      | Ruim                | Baixa  | Nenhuma  | \$0 a \$15k    | Autônomo     | Jovem  | Alto     |
| 9 E8      | Ruim                | Baixa  | Adequada | Acima de \$35k | Fixo         | Adulto | Moderado |
| 10 E9     | Boa                 | Baixa  | Nenhuma  | Acima de \$35k | Fixo         | Jovem  | Baixo    |
| 11 E10    | Boa                 | Alta   | Adequada | Acima de \$35k | Fixo         | Adulto | Baixo    |
| 12 E11    | Boa                 | Alta   | Nenhuma  | \$0 a \$15k    | Autônomo     | Jovem  | Alto     |
| 13 E12    | Boa                 | Alta   | Nenhuma  | \$15 a \$35k   | Fixo         | Jovem  | Moderado |
| 14 E13    | Boa                 | Alta   | Nenhuma  | Acima de \$35k | Fixo         | Adulto | Baixo    |
| 15 E14    | Ruim                | Alta   | Nenhuma  | \$15 a \$35k   | Desempregado | Adulto | Alto     |
| 16 E15    | Boa                 | Baixa  | Adequada | \$15 a \$35k   | Fixo         | Adulto | Baixo    |
| 17 E16    | Ruim                | Alta   | Nenhuma  | \$0 a \$15k    | Desempregado | Jovem  | Alto     |
| 18 E17    | Desconhecida        | Baixa  | Adequada | \$15 a \$35k   | Autônomo     | Adulto | Moderado |
| 19 E18    | Boa                 | Baixa  | Nenhuma  | Acima de \$35k | Fixo         | Adulto | Baixo    |
| 20 E19    | Ruim                | Alta   | Adequada | \$15 a \$35k   | Fixo         | Adulto | Moderado |
| 21 E20    | Desconhecida        | Alta   | Nenhuma  | \$0 a \$15k    | Desempregado | Adulto | Alto     |
| 22 E21    | Boa                 | Alta   | Adequada | Acima de \$35k | Autônomo     | Adulto | Baixo    |
| 23 E22    | Ruim                | Baixa  | Nenhuma  | \$15 a \$35k   | Fixo         | Jovem  | Moderado |
| 24 E23    | Desconhecida        | Baixa  | Nenhuma  | Acima de \$35k | Fixo         | Adulto | Baixo    |
| 25 E24    | Ruim                | Alta   | Nenhuma  | \$0 a \$15k    | Autônomo     | Jovem  | Alto     |
| 26 E25    | Boa                 | Baixa  | Adequada | \$0 a \$15k    | Fixo         | Adulto | Moderado |
| 27 E26    | Desconhecida        | Alta   | Adequada | Acima de \$35k | Fixo         | Jovem  | Baixo    |
| 28 E27    | Boa                 | Baixa  | Nenhuma  | \$15 a \$35k   | Autônomo     | Jovem  | Moderado |
| 29 E28    | Ruim                | Alta   | Nenhuma  | Acima de \$35k | Desempregado | Adulto | Alto     |
| 30 E29    | Desconhecida        | Baixa  | Adequada | \$0 a \$15k    | Fixo         | Adulto | Moderado |
| 31 E30    | Boa                 | Alta   | Nenhuma  | \$0 a \$15k    | Fixo         | Jovem  | Alto     |

## 1.2 (ii) Construção manual das árvores

### 1.2.1 Algoritmo ID3:

O algoritmo ID3 utiliza o Ganho de Informação baseado na Entropia de Shannon para escolher os nós. A fórmula da Entropia é  $H(S) = - \sum p_i \log_2(p_i)$ . O ID3 cria ramificações múltiplas para cada valor categórico do atributo escolhido.

Ao particionar o conjunto S pelos valores possíveis v de um determinado atributo N, a entropia esperada da partição é calculada pela média ponderada das entropias dos subconjuntos  $S_v$ :  $H(S,N) = \sum |S_v|/|S| H(S_v)$

$$v \in \text{Valores}(N)$$

O Ganho de Informação  $IG(S,N)$  mede a redução esperada na entropia obtida ao segmentar S segundo o atributo N:  $IG(S,N) = H(S) - H(S,N)$

Ao fazer os cálculos, encontraremos qual deve ser a raiz da nossa árvore.

#### Entropia Inicial (Conjunto S0)

$$H(S_0) = - \left(\frac{11}{30}\right) \log_2\left(\frac{11}{30}\right) - \left(\frac{9}{30}\right) \log_2\left(\frac{9}{30}\right) - \left(\frac{10}{30}\right) \log_2\left(\frac{10}{30}\right)$$

$$H(S_0) \approx 0,5307 + 0,5211 + 0,5283 \approx 1,5801$$

#### 1.2.1.1 Cálculos de Entropia e Ganho de Informação por Atributo

#### HISTÓRIA DE CRÉDITO

- **Boa** (11 ex: 2A, 3M, 6B):  $H(S_{Boa}) = - \left(\frac{2}{11}\right) \log_2\left(\frac{2}{11}\right) - \left(\frac{3}{11}\right) \log_2\left(\frac{3}{11}\right) - \left(\frac{6}{11}\right) \log_2\left(\frac{6}{11}\right) \approx 1,434$
- **Desconhecida** (10 ex: 3A, 3M, 4B):  $H(S_{Desc}) = - (0,3) \log_2(0,3) - (0,3) \log_2(0,3) - (0,4) \log_2(0,4) \approx 1,571$
- **Ruim** (9 ex: 6A, 3M, 0B):  $H(S_{Ruim}) = - \left(\frac{6}{9}\right) \log_2\left(\frac{6}{9}\right) - \left(\frac{3}{9}\right) \log_2\left(\frac{3}{9}\right) \approx 0,918$
- **Entropia Ponderada:**  $\left(\frac{11}{30} \times 1,434\right) + \left(\frac{10}{30} \times 1,571\right) + \left(\frac{9}{30} \times 0,918\right) \approx 1,3249$
- **Ganho:**  $1,5801 - 1,3249 = 0,2552$

#### DÍVIDA

- **Alta** (15 ex: 9A, 2M, 4B):
- $H(S_{Alta}) = - \left(\frac{9}{15}\right) \log_2\left(\frac{9}{15}\right) - \left(\frac{2}{15}\right) \log_2\left(\frac{2}{15}\right) - \left(\frac{4}{15}\right) \log_2\left(\frac{4}{15}\right) \approx 1,338$
- **Baixa** (15 ex: 2A, 7M, 6B):  $H(S_{Baixa}) = - \left(\frac{2}{15}\right) \log_2\left(\frac{2}{15}\right) - \left(\frac{7}{15}\right) \log_2\left(\frac{7}{15}\right) - \left(\frac{6}{15}\right) \log_2\left(\frac{6}{15}\right) \approx 1,429$

- **Entropia Ponderada:**  $(\frac{15}{30} \times 1,338) + (\frac{15}{30} \times 1,429) \approx 1,3835$
- **Ganho:**  $1,5801 - 1,3835 = 0,1966$

## GARANTIA

- **Nenhuma** (20 ex: 11A, 4M, 5B):  $H(S_{\text{Nenhuma}}) = -(\frac{11}{20})\log_2(\frac{11}{20}) - (\frac{4}{20})\log_2(\frac{4}{20}) - (\frac{5}{20})\log_2(\frac{5}{20}) \approx 1,438$
- **Adequada** (10 ex: 0A, 5M, 5B):  $H(S_{\text{Adequada}}) = -(0,5)\log_2(0,5) - (0,5)\log_2(0,5) = 1,000$
- **Entropia Ponderada:**  $(\frac{20}{30} \times 1,438) + (\frac{10}{30} \times 1,000) \approx 1,2920$
- **Ganho:**  $1,5801 - 1,2920 = 0,2881$

## RENDA

- **\$0 a \$15k** (10 ex: 8A, 2M, 0B):  $H(S_{0-15k}) = -(0,8)\log_2(0,8) - (0,2)\log_2(0,2) \approx 0,7219$
- **\$15 a \$35k** (9 ex: 2A, 6M, 1B):  $H(S_{15-35k}) = -(\frac{2}{9})\log_2(\frac{2}{9}) - (\frac{6}{9})\log_2(\frac{6}{9}) - (\frac{1}{9})\log_2(\frac{1}{9}) \approx 1,224$
- **Acima de \$35k** (11 ex: 1A, 1M, 9B):  $H(S_{>35k}) = -(\frac{1}{11})\log_2(\frac{1}{11}) - (\frac{1}{11})\log_2(\frac{1}{11}) - (\frac{9}{11})\log_2(\frac{9}{11}) \approx 0,865$
- **Entropia Ponderada:**  $(\frac{10}{30} \times 0,7219) + (\frac{9}{30} \times 1,224) + (\frac{11}{30} \times 0,865) \approx 0,9250$
- **Ganho:**  $1,5801 - 0,9250 = 0,6551$

## EMPREGO

- **Fixo** (18 ex: 2A, 7M, 9B):  $H(S_{\text{Fixo}}) = -(\frac{2}{18})\log_2(\frac{2}{18}) - (\frac{7}{18})\log_2(\frac{7}{18}) - (\frac{9}{18})\log_2(\frac{9}{18}) \approx 1,382$
- **Autônomo** (7 ex: 4A, 2M, 1B):  $H(S_{\text{Autônomo}}) = -(\frac{4}{7})\log_2(\frac{4}{7}) - (\frac{2}{7})\log_2(\frac{2}{7}) - (\frac{1}{7})\log_2(\frac{1}{7}) \approx 1,378$
- **Desempregado** (5 ex: 5A, 0M, 0B):  $H(S_{\text{Desempregado}}) = -(1)\log_2(1) = 0,000$
- **Entropia Ponderada:**  $(\frac{18}{30} \times 1,382) + (\frac{7}{30} \times 1,378) + (\frac{5}{30} \times 0) \approx 1,1507$
- **Ganho:**  $1,5801 - 1,1507 = 0,4294$

## IDADE

- **Adulto** (18 ex: 5A, 5M, 8B):  $H(S_{\text{Adulto}}) = -(\frac{5}{18})\log_2(\frac{5}{18}) - (\frac{5}{18})\log_2(\frac{5}{18}) - (\frac{8}{18})\log_2(\frac{8}{18}) \approx 1,547$
- **Jovem** (12 ex: 6A, 4M, 2B):  $H(S_{\text{Jovem}}) = -(\frac{6}{12})\log_2(\frac{6}{12}) - (\frac{4}{12})\log_2(\frac{4}{12}) - (\frac{2}{12})\log_2(\frac{2}{12}) \approx 1,459$
- **Entropia Ponderada:**  $(\frac{18}{30} \times 1,547) + (\frac{12}{30} \times 1,459) \approx 1,5116$
- **Ganho:**  $1,5801 - 1,5116 = 0,0685$

### 1.2.1.2. Conclusão da Raiz

Comparando todos os ganhos de informação gerados a partir da base em:

- **Renda:** 0,6551
- **Emprego:** 0,4294
- **Garantia:** 0,2881
- **História de Crédito:** 0,2552
- **Dívida:** 0,1966
- **Idade:** 0,0685

O atributo **Renda** possui o maior Ganho de Informação e, portanto, será o nó raiz da árvore de decisão gerada pelo algoritmo ID3.

A partir do nó raiz **Renda**, a base de dados de 30 exemplos divide-se em três subconjuntos. Para prosseguir com o algoritmo ID3, calculamos a entropia e o ganho de informação para cada ramo subsequente, avaliando os atributos restantes.

**Ramo 1:** Renda = "\$0 a \$15k"

Este subconjunto contém 10 exemplos: E1, E4, E7, E11, E16, E20, E24, E25, E29, E30.

- **Distribuição das classes:** 8 Alto, 2 Moderado, 0 Baixo.
- **Entropia Inicial:**  $H(S_{0-15k}) = - (0,8)\log_2(0,8) - (0,2)\log_2(0,2) \approx 0,7219$

Ao analisar os atributos para estes 10 exemplos, o atributo **Garantia** fornece uma separação perfeita:

- **Nenhuma** (8 exemplos: E1, E4, E7, E11, E16, E20, E24, E30): Todos são da classe **Alto**.  $H(\text{Nenhuma}) = 0$
- **Adequada** (2 exemplos: E25, E29): Todos são da classe **Moderado**.  $H(\text{Adequada}) = 0$
- **Ganho de Informação (Garantia):**  $0,7219 - 0 = 0,7219$  (Ganho máximo possível. Este nó torna-se folha).

**Ramo 2:** Renda = "\$15k a \$35k"

Este subconjunto contém 9 exemplos: E2, E3, E12, E14, E15, E17, E19, E22, E27.

- **Distribuição das classes:** 2 Alto, 6 Moderado, 1 Baixo.
- **Entropia Inicial:**  $H(S_{15-35k}) = - (\frac{2}{9})\log_2(\frac{2}{9}) - (\frac{6}{9})\log_2(\frac{6}{9}) - (\frac{1}{9})\log_2(\frac{1}{9}) \approx 1,224$

Testando os atributos restantes, o **Emprego** apresenta o maior ganho de informação:

- **Fixo** (5 ex: 0 Alto, 4 Mod, 1 Baixo):  $H(\text{Fixo}) \approx 0,722$
- **Autônomo** (3 ex: 1 Alto, 2 Mod, 0 Baixo):  $H(\text{Aut}) \approx 0,918$
- **Desempregado** (1 ex: 1 Alto):  $H(\text{Desemp}) = 0$  (Folha: Alto)
- **Ganho (Emprego):**  $1,224 - [(\frac{5}{9} \times 0,722) + (\frac{3}{9} \times 0,918)] \approx 0,517$

Como os nós "Fixo" e "Autônomo" não são puros, exigem novas ramificações:

**Sub-ramo Emprego = Autônomo** (3 ex: E2, E17, E27): A entropia é 0,918. Escolhe-se o atributo Dívida para desempatar, pois separa perfeitamente:

- Dívida Alta → Alto (E2)

- Dívida Baixa → Moderado (E17, E27)

**Sub-ramo Emprego = Fixo** (5 ex: E3, E12, E15, E19, E22; 4 Moderado e 1 Baixo,  $H \approx 0,722$ ). Calculando o ganho dos atributos restantes:

- **Idade:** Jovem (E3, E12, E22: todos Moderado,  $H = 0$ ) e Adulto (E15 Baixo, E19 Moderado,  $H = 1$ ). Ganho =  $0,722 - (2/5 \times 1) \approx 0,322$ .
- **História de Crédito:** Boa (E12, E15,  $H = 1$ ), Desconhecida (E3,  $H = 0$ ) e Ruim (E19, E22,  $H = 0$ ). Ganho  $\approx 0,322$ .
- **Garantia:** Nenhuma (E3, E12, E22,  $H = 0$ ) e Adequada (E15, E19,  $H = 1$ ). Ganho  $\approx 0,322$ .
- **Dívida:** ganho  $\approx 0,171$ .

Idade, História de Crédito e Garantia empatam em 0,322, e nenhuma separa o subconjunto por completo. Escolhe-se Idade no desempate.

- Idade = Jovem → Moderado (E3, E12, E22).
- Idade = Adulto (E15, E19) ainda é impuro. História de Crédito o separa: Boa → Baixo (E15) e Ruim → Moderado (E19).

**Ramo 3:** Renda = "Acima de \$35k"

Este subconjunto contém 11 exemplos: E5, E6, E8, E9, E10, E13, E18, E21, E23, E26, E28.

- **Distribuição das classes:** 1 Alto, 1 Moderado, 9 Baixo.
- **Entropia Inicial:**

$$H(S_{>35k}) = - \left(\frac{1}{11}\right)\log_2\left(\frac{1}{11}\right) - \left(\frac{1}{11}\right)\log_2\left(\frac{1}{11}\right) - \left(\frac{9}{11}\right)\log_2\left(\frac{9}{11}\right) \approx 0,865$$

Ao calcular a entropia ponderada, a **História de Crédito** oferece o melhor ganho de informação:

- **Boa** (5 ex: E9, E10, E13, E18, E21): 5 Baixo.  $H(Boa) = 0$
- **Desconhecida** (4 ex: E5, E6, E23, E26): 4 Baixo.  $H(Desc) = 0$
- **Ruim** (2 ex: E8, E28): 1 Alto, 1 Moderado.  $H(Ruim) = 1,0$
- **Ganho (Hist. Crédito):**  $0,865 - \left(\frac{2}{11} \times 1,0\right) \approx 0,683$


O nó "História = Ruim" (E8, E28) precisa de ser subdividido pois a entropia é máxima (1,0).

Utilizando o atributo **Dívida** (ou Emprego/Garantia, que também separariam a 100%), obtemos nós puros:

- Dívida Alta → Alto (E28)
- Dívida Baixa → Moderado (E8)

Unindo todos os cálculos efetuados sobre a tabela da imagem, a estrutura completa da árvore ID3 é:

## ÁRVORE ID3



- **Renda**

- **\$0 a \$15k: Garantia**

- Nenhuma → Alto

- Adequada → Moderado

- **\$15k a \$35k: Emprego**

- Desempregado → Alto

- Autônomo → Dívida

- Alta → Alto

- Baixa → Moderado

- Fixo → Idade

- Jovem → Moderado

- Adulto → História de crédito

- Boa → Baixo

- Ruim → Moderado

- **Acima de \$35k:** História de Crédito

Boa → Baixo

Desconhecida → Baixo

Ruim → Dívida

-Alta → Alto

-Baixa → Moderado

### 1.2.2 Algoritmo C4.5:

Para o algoritmo C4.5, substitui-se o critério do Ganho de Informação (Information Gain) pela Razão de Ganho (Gain Ratio). Esta métrica penaliza atributos com muitos valores distintos através do cálculo da Informação de Divisão (Split Information).

As fórmulas matemáticas base são:

$$SplitInfo(S, A) = - \sum_{i=1}^c \frac{|S_i|}{|S|} \log_2 \left( \frac{|S_i|}{|S|} \right)$$

$$GainRatio(S, A) = \frac{Gain(S, A)}{SplitInfo(S, A)}$$

#### 1.2.2.1 Cálculos para o Nó Raiz

Utilizando os ganhos de informação (Gain) já calculados anteriormente para o nó inicial, calcula-se o SplitInfo e a GainRatio para cada atributo.

**REND**A (\$0 a \$15k: 10, \$15k a \$35k: 9, Acima de \$35k: 11)

$$SplitInfo = - \left( \frac{10}{30} \log_2 \frac{10}{30} + \frac{9}{30} \log_2 \frac{9}{30} + \frac{11}{30} \log_2 \frac{11}{30} \right) \approx 1,5801$$

$$GainRatio = \frac{0,6551}{1,5801} = 0,4146$$

**EMPREGO** (Fixo: 18, Autônomo: 7, Desempregado: 5)

$$SplitInfo = - \left( \frac{18}{30} \log_2 \frac{18}{30} + \frac{7}{30} \log_2 \frac{7}{30} + \frac{5}{30} \log_2 \frac{5}{30} \right) \approx 1,3630$$

$$GainRatio = \frac{0,4294}{1,3630} \approx 0,3150$$

**GARANTIA** (Nenhuma: 20, Adequada: 10)

$$SplitInfo = - \left( \frac{20}{30} \log_2 \frac{20}{30} + \frac{10}{30} \log_2 \frac{10}{30} \right) \approx 0,9183$$

$$GainRatio = \frac{0,2881}{0,9183} = 0,3132$$

**HISTÓRIA DE CRÉDITO** (Boa: 11, Desconhecida: 10, Ruim: 9)

$$SplitInfo = - \left( \frac{11}{30} \log_2 \frac{11}{30} + \frac{10}{30} \log_2 \frac{10}{30} + \frac{9}{30} \log_2 \frac{9}{30} \right) \approx 1,5801$$

$$GainRatio = \frac{0,2552}{1,5801} = 0,1612$$

**DÍVIDA** (Alta: 15, Baixa: 15)

$$SplitInfo = - \left( \frac{15}{30} \log_2 \frac{15}{30} + \frac{15}{30} \log_2 \frac{15}{30} \right) = 1,0000$$

$$GainRatio = \frac{0,1966}{1,0000} = 0,1966$$

**IDADE** (Adulto: 18, Jovem: 12)

$$SplitInfo = - \left( \frac{18}{30} \log_2 \frac{18}{30} + \frac{12}{30} \log_2 \frac{12}{30} \right) \approx 0,9710$$

$$GainRatio = \frac{0,0685}{0,9710} = 0,0706$$

O ganho médio é 0,3152. Só Renda e Emprego o superam, e **Renda** tem a maior Razão de Ganho, então é a raiz.

**Ramo 1:** Renda = "\$0 a \$15k" (10 exemplos: 8 Alto, 2 Moderado)

Garantia separa perfeitamente os dados (Nenhuma → Alto; Adequada → Moderado). Seu ganho é 0,7219 e o SplitInfo também, logo a Razão de Ganho é 1,0000, a máxima possível. Esse é o mesmo resultado do ID3.

**Ramo 2:** Renda = "\$15k a \$35k" (9 exemplos: 2 Alto, 6 Moderado, 1 Baixo)

O ganho médio é 0,3330, e só Emprego (0,5172) e Dívida (0,3789) o superam.

- Emprego: SplitInfo = 1,3516, Razão de Ganho = 0,3827
- Dívida: SplitInfo = 0,9911, Razão de Ganho = 0,3823

Emprego vence por pequena margem, como no ID3.

- Desempregado (1 ex) → Alto
- Autônomo (E2, E17, E27): Dívida separa perfeitamente (razão de ganho 1,0): Alta → Alto; Baixa → Moderado

- Fixo (E3, E12, E15, E19, E22): Idade, História de Crédito e Garantia têm o mesmo ganho ( $\approx 0,322$ ). Idade e Garantia dividem em 2 ramos (SplitInfo  $\approx 0,971$ ) e têm Razão de Ganho  $\approx 0,332$ , acima da de História de Crédito ( $\approx 0,212$ ). Idade e Garantia empatam, e adota-se Idade.
  - Jovem  $\rightarrow$  Moderado (E3, E12, E22).
  - Adulto (E15 Baixo, E19 Moderado) ainda é impuro. História de Crédito o separa: Boa  $\rightarrow$  Baixo (E15) e Ruim  $\rightarrow$  Moderado (E19).

**Ramo 3:** Renda = "Acima de \$35k" (11 exemplos: 1 Alto, 1 Moderado, 9 Baixo)

Este subconjunto tem 11 exemplos (E5, E6, E8, E9, E10, E13, E18, E21, E23, E26, E28): 1 Alto, 1 Moderado e 9 Baixo, com  $H(S) \approx 0,8659$ .

Cálculo do Emprego:  $H(\text{Fixo}) = 0,5033$ ,  $H(\text{Autônomo}) = 0$  e  $H(\text{Desempregado}) = 0$ . A entropia ponderada é  $(9/11 \times 0,5033) = 0,4118$ , então o ganho é  $0,8659 - 0,4118 = 0,4541$ .


O ganho médio é  $(0,6841 + 0,1831 + 0,1831 + 0,4541 + 0,0588) / 5 \approx 0,3126$ . Apenas História de Crédito (0,6841) e Emprego (0,4541) o superam. Entre os dois, vence o de maior Razão de Ganho, que é Emprego (0,5245 contra 0,4576). O SplitInfo de História é maior porque ela se divide em subconjuntos mais equilibrados (5, 4 e 2), enquanto Emprego tem uma partição desbalanceada (9, 1 e 1).

Esse é o ponto em que o C4.5 diverge do ID3, o ID3 escolhe História de Crédito (maior ganho), e o C4.5 escolhe Emprego (maior razão).

- Desempregado (E28)  $\rightarrow$  Alto (puro).
- Autônomo (E21)  $\rightarrow$  Baixo (puro).
- Fixo (9 ex: 8 Baixo, 1 Moderado,  $H = 0,5033$ )  $\rightarrow$  ainda impuro, precisa de nova ramificação.

**Sub-ramo** Emprego = Fixo (E5, E6, E8, E9, E10, E13, E18, E23, E26). O ganho médio é 0,1898 e só a História de Crédito o supera. Ela separa perfeitamente: Boa (E9, E10, E13, E18)  $\rightarrow$  Baixo; Desconhecida (E5, E6, E23, E26)  $\rightarrow$  Baixo; Ruim (E8)  $\rightarrow$  Moderado.

A estrutura final da árvore C4.5 é a seguinte:



- Renda
  - \$0 a \$15k: Garantia
    - Nenhuma → Alto
    - Adequada → Moderado
  - \$15k a \$35k: Emprego
    - Desempregado → Alto
    - Autônomo → Dívida
      - Alta → Alto
      - Baixa → Moderado
    - Fixo → Idade
      - Jovem → Moderado
      - Adulto → História de Crédito
        - Boa → Baixo
        - Ruim → Moderado
  - Acima de \$35k: Emprego
    - Desempregado → Alto
    - Autônomo → Baixo
    - Fixo → História de Crédito
      - Boa → Baixo
      - Desconhecida → Baixo
      - Ruim → Moderado

### 1.2.3 Algoritmo CART:

O algoritmo CART (Classification and Regression Trees) constrói árvores estritamente binárias (decisões Sim/Não) baseadas na Impureza de Gini em vez do Ganho de Informação baseado na Entropia.

A fórmula da Impureza de Gini para um nó é calculada por:

$$Gini(S) = 1 - \sum p_i^2$$

A avaliação de um atributo  $A$  resulta na média ponderada da impureza dos dois subconjuntos gerados (Sim e Não).:

$$Gini_A(S) = \frac{|S_{Sim}|}{|S|} Gini(S_{Sim}) + \frac{|S_{Não}|}{|S|} Gini(S_{Não})$$

O objetivo do algoritmo é encontrar a divisão binária que resulte no menor  $Gini_A(S)$  possível.

#### 1.2.3.1 Cálculos de Gini para o Nó Raiz

A partir dos dados da tabela com 30 exemplos (11 Alto, 9 Moderado, 10 Baixo), calcula-se o Gini inicial:

$$Gini(S_0) = 1 - \left[ \left( \frac{11}{30} \right)^2 + \left( \frac{9}{30} \right)^2 + \left( \frac{10}{30} \right)^2 \right] = 1 - \left[ \frac{121}{900} + \frac{81}{900} + \frac{100}{900} \right] \approx 0,6644$$

Como o CART apenas permite divisões binárias, os atributos com três categorias devem ser testados em combinações de um contra o resto. Abaixo estão os testes das principais divisões candidatas para a raiz:

- **Teste 1:** Renda == "Acima de \$35k"
  - **Sim (11 ex):** 1 Alto, 1 Moderado, 9 Baixo.  

$$Gini_{sim} = 1 - \left[ \left( \frac{1}{11} \right)^2 + \left( \frac{1}{11} \right)^2 + \left( \frac{9}{11} \right)^2 \right] = 1 - \frac{83}{121} \approx 0,3140$$
  - **Não (19 ex):** 10 Alto, 8 Moderado, 1 Baixo.  

$$Gini_{\sim} = 1 - \left[ \left( \frac{10}{19} \right)^2 + \left( \frac{8}{19} \right)^2 + \left( \frac{1}{19} \right)^2 \right] = 1 - \frac{165}{361} \approx 0,5429$$
  - **Gini Ponderado:**  $\left( \frac{11}{30} \times 0,3140 \right) + \left( \frac{19}{30} \times 0,5429 \right) \approx 0,4589$
- **Teste 2:** Renda == "\$0 a \$15k"
  - **Sim (10 ex):** 8 Alto, 2 Moderado, 0 Baixo.  

$$Gini_{sim} = 1 - \left[ \left( \frac{8}{10} \right)^2 + \left( \frac{2}{10} \right)^2 \right] = 0,3200$$
  - **Não (20 ex):** 3 Alto, 7 Moderado, 10 Baixo.  

$$Gini_{\sim} = 1 - \left[ \left( \frac{3}{20} \right)^2 + \left( \frac{7}{20} \right)^2 + \left( \frac{10}{20} \right)^2 \right] = 0,6050$$
  - **Gini Ponderado:**  $\left( \frac{10}{30} \times 0,3200 \right) + \left( \frac{20}{30} \times 0,6050 \right) \approx 0,5100$
- **Teste 3:** Emprego == "Fixo"

- **Sim (18 ex):** (18 ex: 2 Alto, 7 Moderado, 9 Baixo):  $Gini \approx 0,5864$
  - **Não (12 ex):** (12 ex: 9 Alto, 2 Moderado, 1 Baixo):  $Gini \approx 0,4028$
  - **Gini Ponderado:**  $(18/30 \times 0,5864) + (12/30 \times 0,4028) \approx 0,5130$
- **Teste 4:** Garantia == "Adequada"
  - **Sim (10 ex):** 0 Alto, 5 Moderado, 5 Baixo.  

$$Gini_{sim} = 1 - [(0,5)^2 + (0,5)^2] = 0,5000$$
  - **Não (20 ex):** 11 Alto, 4 Moderado, 5 Baixo.  

$$Gini_{nao} \approx 1 - \left[ \left(\frac{11}{20}\right)^2 + \left(\frac{4}{20}\right)^2 + \left(\frac{5}{20}\right)^2 \right] = 0,5950$$
  - **Gini Ponderado:**  $\left(\frac{10}{30} \times 0,5000\right) + \left(\frac{20}{30} \times 0,5950\right) \approx 0,5633$

O menor Gini ponderado é alcançado com a divisão Renda == "Acima de \$35k" (0,4589). Este teste torna-se o nó raiz da árvore CART.

#### 1.2.3.2 Nó 1: Renda = "Acima de \$35k" → SIM:

Contém 11 exemplos (E5, E6, E8, E9, E10, E13, E18, E21, E23, E26, E28): 9 Baixo, 1 Moderado e 1 Alto, com  $Gini = 0,3140$ .

- História de Crédito = "Ruim" = 0,0909
- Emprego = "Desempregado" = 0,1636
- Emprego = "Fixo" = 0,2525

História de Crédito = "Ruim" é a melhor divisão:

- **Não** (9 ex, todos Baixo;  $Gini = 0$ ) → folha **BAIXO**.
- **Sim** (E8 Moderado e E28 Alto;  $Gini = 0,5$ ). A divisão Dívida = "Alta" tem Gini ponderado 0 e produz folhas puras:
  - Dívida = "Alta" (E28) → **ALTO**
  - Dívida ≠ "Alta" (E8) → **MODERADO**

#### 1.2.3.3: Nó 2: Renda = "Acima de \$35k" → NÃO

Contém 19 exemplos: 10 Alto, 8 Moderado e 1 Baixo, com  $Gini = 0,5429$ .

- Garantia = "Adequada" = 0,3850
- Dívida = "Alta" = 0,4023
- Emprego = "Fixo" = 0,4023
- Renda "\$0 a \$15k" = 0,4023

Garantia = "Adequada" é a melhor divisão: Sim (5 ex: 4 Moderado, 1 Baixo;  $Gini = 0,3200$ ) e Não (14 ex: 10 Alto, 4 Moderado;  $Gini = 0,4082$ ).

#### 1.2.3.4: Nó 3: Garantia = "Adequada" → SIM

Contém 5 exemplos (E15, E17, E19, E25, E29): 4 Moderado e 1 Baixo, com  $Gini = 0,3200$ .

- História de crédito = "Boa" = 0,2
- História de crédito = "Desconhecida" = 0,2667
- Renda "\$0 a \$15k" = 0,2667

História de Crédito  $\neq$  "Boa" (E17, E19, E29; todos Moderado)  $\rightarrow$  folha MODERADO.

História de Crédito = "Boa" (E15 Baixo e E25 Moderado; Gini = 0,5). A divisão Renda = "\$15k a \$35k" separa perfeitamente:

- Renda = "\$15k a \$35k" (E15)  $\rightarrow$  BAIXO
- Renda  $\neq$  "\$15k a \$35k" (E25)  $\rightarrow$  MODERADO

#### 1.2.3.5: Nó 4: Garantia = "Adequada" $\rightarrow$ NÃO

Contém 14 exemplos: 10 Alto e 4 Moderado, com Gini = 0,4082.

- Renda = "\$15k a \$35k" = 0,1905
- Dívida = "Alta" = 0,2984
- Emprego = "Fixo" = 0,2984


Renda = "\$15k a \$35k" é a melhor divisão (empatada com renda = "\$0 a \$15k", que gera a mesma partição):

Renda  $\neq$  "\$15k a \$35k" (8 ex, todos Alto; Gini = 0)  $\rightarrow$  folha ALTO.

Renda = "\$15k a \$35k" (E2, E3, E12, E14, E22, E27: 2 Alto e 4 Moderado; Gini = 0,4444). Aqui Emprego = "Fixo" e Dívida = "Alta" empatam com Gini ponderado 0,2222, e foi adotado Emprego = "Fixo":

- Emprego = "Fixo" (E3, E12, E22; todos Moderado)  $\rightarrow$  folha MODERADO.
- Emprego  $\neq$  "Fixo" (E2 Alto, E14 Alto, E27 Moderado; Gini = 0,4444). A divisão Dívida = "Baixa" separa perfeitamente:
  - Dívida = "Baixa" (E27)  $\rightarrow$  MODERADO
  - Dívida  $\neq$  "Baixa" (E2, E14)  $\rightarrow$  ALTO

Por fim, a árvore gerada pelo algoritmo CART é a seguinte:



- Renda == "Acima de \$35k"?
  - SIM  $\rightarrow$  História de Crédito == "Ruim"?
    - SIM  $\rightarrow$  Dívida == "Alta"?
      - SIM  $\rightarrow$  Classe ALTO

-NÃO → Classe MODERADO  
 -NÃO → Classe BAIXO  
 NÃO → Garantia == "Adequada"?  
 -SIM → História de Crédito == "Boa"?  
 -SIM → Renda == "\$15k a \$35k"?  
 -SIM → Classe BAIXO  
 -NÃO → Classe MODERADO  
 -NÃO → Classe MODERADO  
 -NÃO → Renda == "\$15k a \$35k"?  
 -SIM → Emprego == "Fixo"?  
 -SIM → Classe MODERADO  
 -NÃO → Dívida == "Baixa"?  
 -SIM → Classe MODERADO  
 -NÃO → Classe ALTO  
 -NÃO → Classe ALTO

### 1.3 (iii) Regras do tipo SE...ENTÃO...

#### 1.3.1 Base de Conhecimento da Árvore ID3

- **R1:** SE Renda = "\$0 a \$15k" E Garantia = "Nenhuma" ENTÃO Risco = Alto
- **R2:** SE Renda = "\$0 a \$15k" E Garantia = "Adequada" ENTÃO Risco = Moderado
- **R3:** SE Renda = "\$15k a \$35k" E Emprego = "Desempregado" ENTÃO Risco = Alto
- **R4:** SE Renda = "\$15k a \$35k" E Emprego = "Autônomo" E Dívida = "Alta" ENTÃO Risco = Alto
- **R5:** SE Renda = "\$15k a \$35k" E Emprego = "Autônomo" E Dívida = "Baixa" ENTÃO Risco = Moderado
- **R6:** SE Renda = "\$15k a \$35k" E Emprego = "Fixo" E Idade = "Jovem" ENTÃO Risco = Moderado
- **R7:** SE Renda = "\$15k a \$35k" E Emprego = "Fixo" E Idade = "Adulto" E História de Crédito = "Boa" ENTÃO Risco = Baixo
- **R8:** SE Renda = "\$15k a \$35k" E Emprego = "Fixo" E Idade = "Adulto" E História de Crédito = "Ruim" ENTÃO Risco = Moderado
- **R9:** SE Renda = "Acima de \$35k" E História de Crédito = "Boa" ENTÃO Risco = Baixo
- **R10:** SE Renda = "Acima de \$35k" E História de Crédito = "Desconhecida" ENTÃO Risco = Baixo
- **R11:** SE Renda = "Acima de \$35k" E História de Crédito = "Ruim" E Dívida = "Alta" ENTÃO Risco = Alto
- **R12:** SE Renda = "Acima de \$35k" E História de Crédito = "Ruim" E Dívida = "Baixa" ENTÃO Risco = Moderado

#### 1.3.2. Base de Conhecimento da Árvore C4.5

- **R1:** SE Renda = "\$0 a \$15k" E Garantia = "Nenhuma" ENTÃO Risco = Alto
- **R2:** SE Renda = "\$0 a \$15k" E Garantia = "Adequada" ENTÃO Risco = Moderado
- **R3:** SE Renda = "\$15k a \$35k" E Emprego = "Desempregado" ENTÃO Risco = Alto

- **R4:** SE Renda = "\$15k a \$35k" E Emprego = "Autônomo" E Dívida = "Alta" ENTÃO Risco = Alto
- **R5:** SE Renda = "\$15k a \$35k" E Emprego = "Autônomo" E Dívida = "Baixa" ENTÃO Risco = Moderado
- **R6:** SE Renda = "\$15k a \$35k" E Emprego = "Fixo" E Idade = "Jovem" ENTÃO Risco = Moderado
- **R7:** SE Renda = "\$15k a \$35k" E Emprego = "Fixo" E Idade = "Adulto" E História de Crédito = "Boa" ENTÃO Risco = Baixo
- **R8:** SE Renda = "\$15k a \$35k" E Emprego = "Fixo" E Idade = "Adulto" E História de Crédito = "Ruim" ENTÃO Risco = Moderado
- **R9:** SE Renda = "Acima de \$35k" E Emprego = "Desempregado" ENTÃO Risco = Alto
- **R10:** SE Renda = "Acima de \$35k" E Emprego = "Autônomo" ENTÃO Risco = Baixo
- **R11:** SE Renda = "Acima de \$35k" E Emprego = "Fixo" E História de Crédito = "Boa" ENTÃO Risco = Baixo
- **R12:** SE Renda = "Acima de \$35k" E Emprego = "Fixo" E História de Crédito = "Desconhecida" ENTÃO Risco = Baixo
- **R13:** SE Renda = "Acima de \$35k" E Emprego = "Fixo" E História de Crédito = "Ruim" ENTÃO Risco = Moderado

### 1.3.3 Base de Conhecimento da Árvore CART

- **R1:** SE Renda = "Acima de \$35k" E História de Crédito = "Ruim" E Dívida = "Alta" ENTÃO Risco = Alto
- **R2:** SE Renda = "Acima de \$35k" E História de Crédito = "Ruim" E Dívida != "Alta" ENTÃO Risco = Moderado
- **R3:** SE Renda = "Acima de \$35k" E História de Crédito != "Ruim" ENTÃO Risco = Baixo
- **R4:** SE Renda != "Acima de \$35k" E Garantia = "Adequada" E História de Crédito = "Boa" E Renda = "\$15k a \$35k" ENTÃO Risco = Baixo
- **R5:** SE Renda != "Acima de \$35k" E Garantia="Adequada" E História de Crédito="Boa" E Renda!="\$15k a \$35k" ENTÃO Risco = Moderado
- **R6:** SE Renda != "Acima de \$35k" E Garantia = "Adequada" E História de Crédito != "Boa" ENTÃO Risco = Moderado
- **R7:** SE Renda != "Acima de \$35k" E Garantia!="Adequada" E Renda="\$15k a \$35k" E Emprego = "Fixo" ENTÃO Risco = Moderado
- **R8:** SE Renda != "Acima de \$35k" E Garantia!="Adequada" E Renda="\$15k a \$35k" E Emprego != "Fixo" E Dívida = "Baixa" ENTÃO Risco = Moderado
- **R9:** SE Renda != "Acima de \$35k" E Garantia!="Adequada" E Renda="\$15k a \$35k" E Emprego != "Fixo" E Dívida != "Baixa" ENTÃO Risco = Alto
- **R10:** SE Renda != "Acima de \$35k" E Garantia!="Adequada" E Renda!="\$15k a \$35k" ENTÃO Risco = Alto

#### 1.4 (iv) Comparação das bases:

##### 1.4.1 ID3 e C4.5:

Ambas usam partições de múltiplas ramificações e condições afirmativas, que mapeiam diretamente a natureza categórica dos atributos (ex.: Renda = "\$15k a \$35k").

As regras R1 a R8 são idênticas. A diferença está no ramo de renda acima de \$35k: o ID3 usa História de Crédito e Dívida (R9 a R12), e o C4.5 usa Emprego e, para emprego fixo, História de Crédito (R9 a R13). O ID3 é um pouco mais enxuto (12 contra 13 regras).

##### 1.4.2 CART:

Tem menos regras, mas condições mais longas, com negações e exclusões sucessivas (por exemplo, Renda  $\neq$  "Acima de \$35k" E Garantia  $\neq$  "Adequada"). Isso dificulta a leitura por um analista e a geração de explicações ao cliente.

##### 1.4.3 Escolha:

A escolha é a base do C4.5, pelos seguintes motivos:

- Explicabilidade: Em sistemas financeiros, o sistema precisa justificar a decisão ao cliente. As regras do C4.5 permitem uma explicação direta, por exemplo: "Seu crédito foi considerado de alto risco porque sua renda está entre \$15k e \$35k e você está desempregado".
- Critério de seleção mais robusto: A Razão de Ganho corrige o viés do ganho de informação a favor de atributos com muitos valores, o que gera árvores menos enviesadas.
- Regras sem dupla negação: O CART depende de negações e exclusões que dificultam a tradução para linguagem natural e prejudicam o módulo de explicação.
- Consistência do conhecimento: Nos dados, os 5 exemplos com Emprego = "Desempregado" têm Risco = Alto. A regra R9 do C4.5 (renda acima de \$35k e desempregado  $\rightarrow$  Alto) reaparece nesse padrão, em linha com R3 (renda de \$15k a \$35k e desempregado  $\rightarrow$  Alto). Embora R9 se apoie em um único exemplo (E28) no seu ramo, ela é coerente com um padrão observado nos demais ramos. No ID3, o mesmo exemplo cai em R11 (história ruim e dívida alta), uma regra que só se justifica por esse exemplo.